


# Regresión polinomial

---


Laboratorio de Datos, IC - FCEN - UBA - 1er. Cuatrimestre 2025

# Regresión Polinomial

Teníamos los datos del precio de Bitcoin durante cierto periodo



El ajuste lineal no explica muy bien la evolución del precio...



$$Y = 45900 + 1,18X$$

$$R^2 \approx 3,81 \times 10^{-5}$$

Obs: el promedio del  
precio en este periodo fue  
de U\$D46005

Cuando la recta no ajusta bien a los datos, podemos intentar ajustarlos con un **polinomio** de grado más grande.

**Recordemos:** polinomio de grado  $n$

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \cdots + \beta_n X^n$$

Supongamos que queremos aproximar los datos con un polinomio de grado *a lo sumo* 5:

$$P(x) = \beta_0 + \beta_1x + \beta_2x^2 + \beta_3x^3 + \beta_4x^4 + \beta_5x^5$$

Supongamos que queremos aproximar los datos con un polinomio de grado *a lo sumo* 5:

$$P(x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 x^4 + \beta_5 x^5$$

Tal cual hicimos con regresión lineal, queremos encontrar los valores de  $\beta_0, \beta_1, \beta_2, \beta_3, \beta_4, \beta_5$  que minimicen los residuos:

$$y_i - P(x_i)$$

Para minimizar los residuos, podemos usar **Cuadrados Mínimos**. Es decir, igual que hicimos con Regresión Lineal, queremos encontrar los  $\beta$  que minimicen la suma de los cuadrados de los residuos:

$$RSS(\beta) = \sum_{i=1}^n (y_i - P(x_i))^2$$



Para minimizar los residuos, podemos usar **Cuadrados Mínimos**. Es decir, igual que hicimos con Regresión Lineal, queremos encontrar los  $\beta$  que minimicen la suma de los cuadrados de los residuos:

$$RSS(\beta) = \sum_{i=1}^n (y_i - P(x_i))^2$$

Las medidas de desempeño del modelo son análogas a las de Regresión Lineal:

$$R^2 = \frac{\sum_{i=1}^n (P(x_i) - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$ECM = \frac{1}{n} \sum_{i=1}^n (y_i - P(x_i))^2$$


Si todo viene siendo muy parecido a Regresión Lineal, entonces deben haber fórmulas *sencillas* para calcular cada  $\beta$ ...

Si todo viene siendo muy parecido a Regresión Lineal, entonces deben haber fórmulas sencillas para calcular cada  $\beta$ ...


Si bien al buscar los mínimos de  $RSS(\beta)$  también se obtiene un sistema de ecuaciones lineales, para calcular el valor de los  $\beta$  necesitamos herramientas que se ven en **Álgebra Lineal Computacional**.

Sin embargo, gracias a seaborn, la visualización es sencilla:

```
.add(so.Line(color='red'), so.PolyFit(1))
```



```
.add(so.Line(color='red'), so.PolyFit(5))
```



## ¿Cómo elegimos el grado del polinomio?

El grado del polinomio es el parámetro del modelo. No hay una fórmula o una regla que nos diga cuál es el grado apropiado para nuestros datos.

## ¿Cómo elegimos el grado del polinomio?

El grado del polinomio es el parámetro del modelo. No hay una fórmula o una regla que nos diga cuál es el grado apropiado para nuestros datos.

Sin embargo, tenemos algunas opciones:

- dividir nuestros datos en un conjunto de entrenamiento y en uno de testeo para probar cuál es el grado que mejor se desempeña.
- tener algún conocimiento específico respecto a nuestros datos.

## ¿Cómo elegimos el grado del polinomio?

El grado del polinomio es el parámetro del modelo. No hay una fórmula o una regla que nos diga cuál es el grado apropiado para nuestros datos.


Sin embargo, tenemos algunas opciones:

- dividir nuestros datos en un conjunto de entrenamiento y en uno de testeo para probar cuál es el grado que mejor se desempeña.
- tener algún conocimiento específico respecto a nuestros datos.


**Obs:** a mayor grado, más complejo es el modelo y mayores son los riesgos de *overfitting* y de tener un problema *mal condicionado*.



# El riesgo del *overfitting*



# El riesgo del *overfitting*



# Bonus: Aplicación de Regresión Lineal

# Media Movil de Cuadrados Minimos

## Least Squares Moving Average (LSMA)

# Media Movil de Cuadrados Minimos

## Least Squares Moving Average (LSMA)



En el mercado bursátil, la LSMA es utilizada como un indicador:

- "Suaviza" el movimiento del precio del activo por lo que captura mejor la **tendencia**.  
**No tiene como objetivo predecir el precio.**
- Temporalmente, se mueve un poco por detrás del precio del activo (*lag*).
- El cruce de dos LSMA de distintos periodos puede ser una señal de compra o de venta.

## ¿Cómo calculamos la LSMA?

Supongamos que tenemos nuestros datos  $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$

Lo primero que hay que hacer es fijar un periodo de tiempo  $k$ .


Notamos como  $\hat{y}_i$  a la estimación de LSMA para  $x_i$  y se calcula de la siguiente manera:

$$\hat{y}_i = \beta_0 + \beta_1 x_i$$

donde  $\beta_0$  y  $\beta_1$  son los coeficientes de la **Regresión Lineal sobre los anteriores  $k$  datos**:


$$\{(x_{i-k-1}, y_{i-k-1}), (x_{i-k}, y_{i-k}), \dots, (x_{i-1}, y_{i-1})\}$$

Construcción de LSMA(5)







Construcción de LSMA(5)




## Construcción de LSMA(5)




Construcción de LSMA(5)




### Construcción de LSMA(5)




Construcción de LSMA(5)




Construcción de LSMA(5)



### Construcción de LSMA(5)




Construcción de LSMA(5)







Construcción de LSMA(5)




Construcción de LSMA(5)




Construcción de LSMA(5)



Construcción de LSMA(5)



Construcción de LSMA(5)



Construcción de LSMA(5)

